

TikTokSafe Sénégal

Plateforme IA de modération multilingue
et de détection des contenus nuisibles

*Proposition de Projet · Veille Technologique / IA & Big
Data*

Département Génie Informatique · Classe L3SRTB ·
ESP/UCAD · 2025–2026

Titre du projet	TikTokSafe Sénégal : Modération automatisée et analyse de sentiment en contexte multilingue (Wolof-Français)
Membres du groupe	Adama Sosso Ibn Alhassane DIALLO · EL Hadji Mamadou NDIAYE · Fatou Binetou LO · Khady SALL · Pape Moussa BA
Classe	L3SRTB — Génie Informatique · École Supérieure Polytechnique · UCAD
Professeur encadrant	M. Doudou FALL
Domaine IA	NLP · Fine-tuning de Transformers · Analyse de sentiments · Détection d'anomalies · Low-resource Languages
Cadre d'application	Sécurité numérique et modération de contenus sur TikTok au Sénégal — contexte multilingue Français-Wolof

Section 1 : Ce que nous voulons faire

1.1 Contexte et problème

L'essor de TikTok au Sénégal s'accompagne d'une propagation massive de contenus problématiques : discours haineux, cyberharcèlement,

désinformation et arnaques. Ces phénomènes touchent des millions d'utilisateurs, notamment les jeunes, dans un contexte où les outils de modération automatique ne sont pas adaptés aux réalités linguistiques et culturelles locales.

Les solutions existantes, souvent entraînées sur l'anglais ou le français standard, échouent à capturer la réalité sénégalaise. La spécificité du contexte local réside dans l'usage intensif du « wolof urbanisé » — un mélange de français et de wolof (code-switching) — pour lequel les modèles d'IA existants restent très insuffisants.

1.2 Notre vision : TikTokSafe Sénégal

Nous voulons créer un pipeline capable de traiter le wolof urbanisé en contexte réel. Le système ne se contentera pas de supprimer les messages : il classera les nuisances par catégorie (haine, arnaque, fake news, cyberharcèlement) et générera des alertes intelligentes via un tableau de bord analytique pour sensibiliser les utilisateurs à la citoyenneté numérique.

L'objectif opérationnel est quadruple :

- Détecter automatiquement les contenus nuisibles sur TikTok (discours haineux, fake news, arnaques, cyberharcèlement) ;
- Analyser les tendances et sentiments autour des sujets viraux au Sénégal ;
- Alerter utilisateurs et modérateurs en temps réel via un tableau de bord dédié ;
- Proposer des recommandations éducatives sur l'usage responsable des réseaux sociaux.

💡 Facteur différenciant : TikTokSafe est spécifiquement conçu pour le Français, le Wolof et le langage mixte Français-Wolof, comblant un manque réel dans le domaine du NLP pour les langues africaines.

Section 2 : Aspects spécifiques de l'IA au cœur du projet

2.1 Architecture générale du pipeline IA

Le système repose sur un pipeline NLP modulaire entièrement original. À l'entrée, les commentaires et légendes de vidéos TikTok sont collectés via l'API publique. Chaque contenu passe par un module de détection de langue

(français, wolof, mixte) avant d'être traité par le modèle de classification approprié.

2.2 Les trois innovations techniques clés

2.2.1 Gestion du Code-Switching (Français-Wolof)

Nous utiliserons l'architecture AfroXLMR ou AfriBERTa, des modèles pré-entraînés sur des corpus africains multilingues. Le défi central réside dans la tokenisation des sous-mots (Byte Pair Encoding, BPE) : le modèle doit reconnaître les racines wolof malgré les variations orthographiques non standardisées (ex : « dina », « dinax », « dina ko »).

Notre stratégie de fine-tuning portera sur un corpus annoté spécifiquement constitué pour ce projet, couvrant les trois registres : français standard, wolof pur et wolof-urbanisé. Nous appliquerons également des techniques d'augmentation de données (back-translation, paraphrase) pour enrichir les classes sous-représentées.

2.2.2 Pondération de la fonction de perte (Weighted Loss)

Les discours haineux sont structurellement moins fréquents que les commentaires neutres dans tout corpus réel. Pour résoudre ce déséquilibre de classes, nous modifierons la fonction de coût (Cross-Entropy Loss) du modèle en attribuant un poids inversement proportionnel à la fréquence de chaque classe — une technique éprouvée qui pénalise plus lourdement les erreurs sur les catégories « nuisibles » lors de l'entraînement.

2.2.3 Détection d'anomalies non supervisée

En complément de la classification supervisée, nous intégrerons un module Isolation Forest basé sur les embeddings textuels extraits de la couche finale du transformer. Ce module permettra de détecter des « pics » de virulence ou des sujets viraux suspects qui ne correspondent pas encore aux patterns connus du classifieur supervisé — une approche hybride supervisée/non-supervisée qui renforce la robustesse du système.

2.3 Bibliothèques et stack technique

- Hugging Face Transformers — fine-tuning, inférence (AfroXLMR, AfriBERTa, CamemBERT)
- PyTorch — entraînement, gestion GPU, Weighted Cross-Entropy
- scikit-learn — Isolation Forest, métriques d'évaluation, TF-IDF baseline

- spaCy / NLTK — pré-traitement, normalisation, tokenisation
- FastAPI — backend API temps réel
- Streamlit — tableau de bord analytique et interface de démonstration
- TikTok Research API / scraping éthique — collecte de données
- Google Colab / Kaggle Notebooks — entraînement GPU gratuit

Section 3 : Évaluation du système

3.1 Métriques de performance quantitatives (Gold Standard)

Nous utiliserons le F1-Score pondéré (Weighted F1) comme métrique principale, plus fiable que la précision brute sur des données déséquilibrées. Notre objectif chiffré est d'atteindre un F1-score $> 0,75$ sur les contenus en Wolof, là où les modèles standards (GPT-4 sans fine-tuning, BERT-base multilingue) obtiennent généralement des scores médiocres sur ces langues.

Métriques secondaires retenues :

- Précision, Rappel, F1-score par classe (haine, fake news, arnaque, cyberharcèlement, neutre) ;
- ROC-AUC pour évaluer la capacité discriminante globale du modèle ;
- Taux de Faux Positifs (FPR) — critique pour ne pas censurer des commentaires amicaux utilisant de l'argot sénégalais mal interprété.

Nous comparerons nos résultats avec : (a) une baseline TF-IDF + SVM, (b) un BERT multilingue non fine-tuné, (c) les performances publiées sur le benchmark AfriSenti-SemEval 2023.

3.2 Comparaison avec la modération humaine

Un sous-ensemble de 300 commentaires (100 par registre linguistique : français, wolof, mixte) sera annoté indépendamment par trois étudiants sénégalais natifs. L'accord inter-annotateurs sera mesuré via le Kappa de Cohen pour valider que notre IA « comprend » les insultes culturelles et l'ironie aussi bien qu'un humain natif.

Objectif : Kappa de Cohen $\geq 0,60$ (accord substantiel) entre notre système automatique et la modération humaine native.

3.3 Tests de robustesse

Nous testerons spécifiquement la capacité du système à ne pas générer de Faux Positifs sur des commentaires amicaux contenant des mots d'argot

sénégalais (ex : « dafa bari » — il/elle est très bien) qui pourraient être mal interprétés hors contexte culturel. Ce test sera mené sur un corpus séparé de 50 exemples adversariaux construits manuellement.

3.4 Tests utilisateurs

Une session de test sera menée auprès d'un panel de 20 étudiants de l'ESP (hors groupe projet), qui évalueront sur une échelle de Likert 1–5 : la pertinence des alertes générées, la clarté des recommandations éducatives et l'acceptabilité globale de l'interface. Les résultats seront agrégés et analysés dans le rapport final.

Section 4 : Calendrier du projet

Période	Étape	Actions clés
Semaines 1–3	Collecte & Data	Scraping éthique TikTok · Constitution d'un dataset de 5 000+ lignes · Labellisation manuelle · Calcul de l'accord inter-annotateurs (Kappa de Cohen)
Semaines 4–6	Prétraitement	Normalisation du texte wolof · Gestion des émojis et caractères spéciaux · Tokenisation spécifique (BPE multilingue) · Augmentation de données
Semaines 7–10	Développement IA	Fine-tuning d'AfroXLMR · Optimisation des hyperparamètres (Grid Search) · Implémentation Weighted Loss · Entraînement Isolation Forest sur embeddings
Semaines 11–12	Intégration	Développement de l'API (FastAPI) · Tableau de bord (Streamlit) · Module d'alertes et assistant éducatif · Tests d'intégration end-to-end
Semaines 13–14	Évaluation & Tests	Tests utilisateurs (20 étudiants ESP) · Calcul des métriques finales · Tests de robustesse adversariaux ·

Période	Étape	Actions clés
		Rédaction du rapport et préparation de la soutenance

Note : Les étapes « Collecte & Data » (S1–3) et « Prétraitement » (S4–6) sont séquentielles et constituent le chemin critique. Les phases de développement IA (S7–10) peuvent être menées en parallèle sur les différents modules.

Section 5 : Ressources existantes

5.1 Logiciels et bibliothèques

- Hugging Face Transformers — modèles AfroXLMR, AfriBERTa, CamemBERT (accès libre, HuggingFace Hub)
- PyTorch 2.x — entraînement des modèles avec support GPU
- scikit-learn — baseline classifieurs, Isolation Forest, métriques
- FastAPI + Streamlit — backend et interface de démonstration (open source)
- Masakhane NLP Toolkit — ressources NLP pour langues africaines (tokeniseurs, modèles de détection de langue)

5.2 Données

- AfriSenti-SemEval 2023 — dataset de sentiments incluant le wolof, disponible sur HuggingFace (shmuhammad/AfriSenti-twitter-sentiment)
- OLID (Offensive Language Identification Dataset) — bootstrap du classifieur de discours haineux en français
- Corpus TikTok propre au projet — 5 000 à 10 000 commentaires issus de vidéos virales sénégalaises (collecte éthique en cours)
- Wikipedia francophone — corpus de pré-entraînement complémentaire si nécessaire

5.3 Infrastructure de calcul

- Google Colab Pro / Kaggle Notebooks — GPU T4/A100 gratuits pour l'entraînement intensif

- GitHub — versionnement du code, CI/CD, documentation

Section 6 : Relation avec d'autres travaux

Ce projet est une création originale développée dans le cadre du cours de Veille Technologique 2025–2026 (M. Doudou FALL). Bien qu'il s'inscrive dans notre passion pour la cybersécurité et le traitement du langage naturel — en lien direct avec notre formation en SRT (Systèmes, Réseaux et Télécommunications) en classe L3SRTB — le code, les modèles et les données développés ici sont entièrement distincts de tout autre projet académique antérieur.

Aucun membre du groupe ne mène de travaux parallèles sur des sujets connexes dans d'autres cours ou structures de recherche. Le projet n'a bénéficié d'aucun financement externe.

Section 7 : Références clés

Articles scientifiques

1. Devlin J. et al. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL-HLT 2019.
2. Conneau A. et al. (2020). Unsupervised Cross-lingual Representation Learning at Scale (XLM-RoBERTa). ACL 2020.
3. Ogueji K. et al. (2021). Small Data? No Problem! Exploring the Viability of Pretrained Multilingual Language Models for Low-resourced Languages (AfriBERTa). MultiLingNLP Workshop, EMNLP 2021.
4. Muhammed T. et al. (2023). AfriSenti-SemEval Shared Task 12: Sentiment Analysis for African Languages. SemEval-2023, ACL.
5. Aluru S. et al. (2021). Deep Learning Models for Multilingual Hate Speech Detection. ECML PKDD 2021.

Ressources en ligne

- Masakhane — Initiative pour le NLP en Afrique : <https://www.masakhane.io/>

- AfriSenti Dataset (HuggingFace) :
<https://huggingface.co/datasets/shmuhammad/AfriSenti-twitter-sentiment>
- AfroXLMR (HuggingFace) : <https://huggingface.co/Davlan/afro-xlmr-large>
- AfriBERTa (HuggingFace) :
https://huggingface.co/castorini/afriberta_large
- TikTok Research API :
<https://developers.tiktok.com/products/research-api/>

Annexe — Architecture fonctionnelle de TikTokSafe

PIPELINE COMPLET : Commentaire TikTok → Détection de langue (FR / WO / Mixte) → Pré-traitement (normalisation, BPE) → Classifieur AfroXLMR fine-tuné → Isolation Forest (anomalies) → Score de risque composite (0–100) → Alerte modérateur / Tableau de bord / Recommandation éducative

Modules principaux

- Module 1 — Collecte : TikTok Research API + scraping éthique, normalisation et déduplication
- Module 2 — Détection de langue : fastText multilingue (français / wolof / code-switching)
- Module 3 — Pré-traitement : tokenisation BPE, gestion émojis, normalisation orthographique wolof
- Module 4 — Classification supervisée : AfroXLMR fine-tuné avec Weighted Loss (haine, fake news, arnaque, cyberharcèlement, neutre)
- Module 5 — Détection d'anomalies : Isolation Forest sur embeddings pour virulence non supervisée
- Module 6 — Scoring : score composite = probabilité classe × poids anomalie
- Module 7 — Tableau de bord (Streamlit) : tendances, cartographie émotions, alertes temps réel
- Module 8 — Assistant éducatif : recommandations personnalisées sur la citoyenneté numérique